Author: 🌑 王蒙

Team: 产品研发和工程架构部-架构-计算-流式计算

Scope: 域内

3

总结:

• 问题背景: Darwin Flink Batch 任务频繁因为 TM 堆外内存超限被 kill,影响作业稳定性;

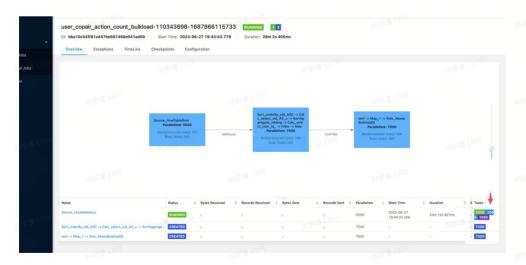
- 影响范围: parquet-zstd 读的场景(跟 zstd codec 的实现有关 parquet-mr-982);
- 问题原因: Hive-Parquet 读取解压时未对 InputStream 及时关闭,导致堆外内存泄露。

背景

近期 Darwin 业务有一个 Flink Batch SQL 任务在线上测试时,经常遇到**任务的 TM 因为内存超限被 kill 的问题,导致任务失败率较高**(退出码是 22001,内存超限被 kill)。

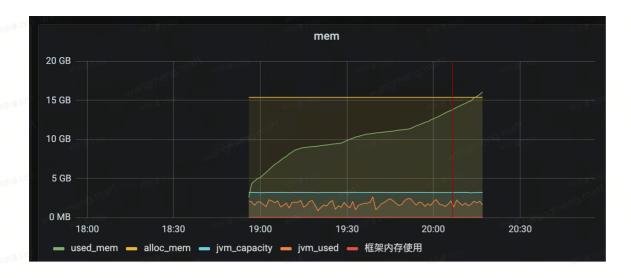


作业的拓扑结构如下:



• 作业配置:

- TM 1core16G, 一个 TM 一个 slot;
- Source 并发 5000,每次最多同时运行 2000 个 Task;
- 作业现象:
 - 。 一个 TM 平均会执行 2-3 个 Source Task,按照上面的配置,第一个 task都可以正常跑完,到第二或第三个启动时,TM 就会因为内存超限被 kill,从监控上可以看到 TM 的内存一直在增加,一个 Task 跑完之后内存并没有释放(确认作业出现堆外内存泄露)。



问题分析

从上面 Container 的内存监控图可以看出,内存的超用是出现在堆外部分(这里的堆外是广义的堆外内存,除了 JVM heap 以外都认为是堆外),任务是也可以稳定性复现,这里通过 Jemalloc profiling(Flink 堆外内存分析用户文档)能力来分析其堆外内存的使用。

Sys 这边有关于 Jemalloc 的文档, **I Jemalloc内存分配与优化实践** , Jemalloc 支持 profiling,分析内存非常方便。

Jemalloc Profile 分析

打开 Jemalloc 的 profile 之后,通过 jeprof 分析 native 内存的使用情况,信息如下:

```
-rw-r--r-- 1 root root 124487 Jun 26 21:36
    jeprof.13.41.i41.heap
    root@dc05-pff-ff-7cd4-66f9-ab20-246f(container-2cc76e43-e58-
    1686204898999-335888-01-000116):/opt/tiger/yodel/container#
     jeprof --show_bytes /opt/tiger/jdk/jdk1.8/bin/java
     jeprof.13.41.i41.heap
    Using local file /opt/tiger/jdk/jdk1.8/bin/java.
    Argument "MSWin32" isn't numeric in numeric eq (==) at
     /usr/local/bin/jeprof line 5124.
    Argument "linux" isn't numeric in numeric eq (==) at
     /usr/local/bin/jeprof line 5124.
    Using local file jeprof.13.41.i41.heap.
    Welcome to jeprof! For help, type 'help'.
7
     (jeprof) top
9
    Total: 46207943356 B
     46207943356 100.0% 100.0% 46207943356 100.0% je_prof_backtrace
10
11
               0.0% 100.0% 43229250742 93.6% 0x00007f69d527fb4a
                                         5.7% 0x00007f69d5315d04
12
            0
               0.0% 100.0% 2635787516
               0.0% 100.0% 2635787516
13
                                         5.7% 0x00007f69d5317c0a
            0
               0.0% 100.0% 43229250742 93.6% 0x00007f69d53189cd
14
15
               0.0% 100.0% 400570049
                                        0.9% 0x00007f6a4dfba773
16
            0
               0.0% 100.0% 2107408
                                       0.0% 0x00007f6a4dfc6759
17
               0.0% 100.0% 2102276
                                       0.0% 0x00007f6a4dfc7758
            0
                                       0.0% 0x00007f6a4e38903b
18
               0.0% 100.0% 2097408
19
               0.0% 100.0% 19022207
                                       0.0% 0x00007f6a4e3cba05
```

使用 Jeprof 程序生成内存透视图:

两个的信息基本一致,这里能看到申请堆外内存,主要是由 0x00007f69d53189cd 这个 进程空间地址所申请的,但是无法看到详情的线程栈信息。

正常情况下这里是可以直接看到具体线程栈调用这里,这次的 case 有一些特殊(引用是一个临时文件,该文件会被清理),无法看不到详细的调用栈信息。

进程 maps 信息分析

与 Sys 通过沟通后,在 /procs/PID/maps 文件中,可以看到进程的内存映射信息,这个文件会记录: 进程加载的库、堆栈、数据和代码段,

- 1 # 0x00007f69d527fb4a/0x00007f69d53189cd 所在地址范围
- 7 7f69d5271000-7f69d5340000 r-xp 00000000 fe:20 124651095
 /opt/tiger/yodel/container/tmp/libzstdjni6415142372855756955.so (deleted)
- 3 7f69d5340000-7f69d5540000 ---p 000cf000 fe:20 124651095 /opt/tiger/yodel/container/tmp/libzstdjni6415142372855756955.so (deleted)

每行的字段信息如下:

	内核每进程的 vm_area_struct项	/proc/pid/maps中 的项	含义 9				
	vm_start	"-"前一列,如 00377000	此段虚拟地址空间起始地址				
	vm_end 何年第1359	"-"后一列,如 00390000	此段虚拟地址空间结束地址				
何	vm_flags	ags 第三列,如r-xp					
	vm_pgoff @## 1359	第四列,如 00000000	对有名映射,表示此段虚拟内存起始地址在文件中以页为单位的偏移。对匿名映射,它等于0或者 vm_start/PAGE_SIZE				
何	vm_file->f_dentry- >d_inode->i_sb->s_dev	第五列,如fd:00	映射文件所属设备号。对匿名映射来说,因为没有文件在磁盘上,所以没有设备号,始终为00:00。 对有名映射来说,是映射的文件所在设备的设备号				
	vm_file->f_dentry- >d_inode->i_ino	第六列,如 9176473	映射文件所属节点号。对匿名映射来说,因为没有文件在磁盘上,所以没有节点号,始终为00:00。 对有名映射来说,是映射的文件的节点号				
	宗康 1359	第七列,如/lib/ld- 2.5.so	对有名来说,是映射的文件名。对匿名映射来说,是此段虚拟内存在进程中的角色。[stack]表示在进程中作为栈使用,[heap]表示堆。其余情况则无显示				

这里,可以定位到 0x00007f69d53189cd 这个地址,指向的是

/opt/tiger/yodel/container/tmp/libzstdjni6415142372855756955.so 的 so 包,这里可以初步定位出来这里的内存主要 是 libzstd-jni 包的所申请的。

内存火焰图分析

参考 🖹 async-profiler ,对于 jemalloc 的内存分配进行 profile 分析:

引用是一个临时文件,该文件会被清理



李本超 2024年1月2日

这个临时文件是怎么判定呢,是 在/tmp 目录里面就是临时文件 嘛?



王蒙 2024年1月2日

@李本超 这个根据地址信息查查找的 maps 文件,能看到【/opt/tiger/yodel/container/tmp/libzstd-jni6415142372855756955.so(deleted)】这个文件路径信息



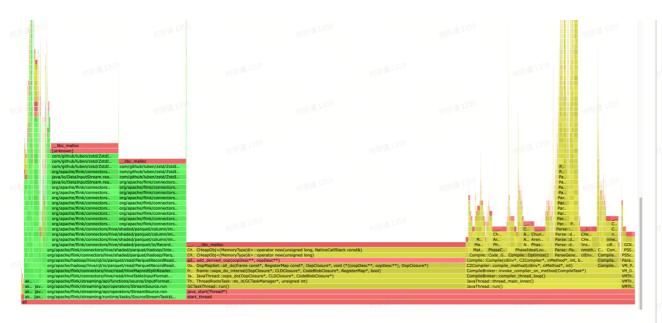
李本超 2024年1月2日

所以可以理解为当前这个工具可以完整应对堆外内存分析是吧, 找到内存占用大头,就能找到对 应的代码?



王蒙 2024年1月2日

@李本超 我理解这个还得跟火 焰图一起交叉来看,火焰图定位 具体的方法会更方便一些。这个 应该只能看到本地文件信息



E Jemalloc 内存差分火焰图 也可以参考这个,分析不同时间段之后,内存变化情况。在这个 case 中,差分图也是只能看到某个进程空间地址在申请内存,无法看到具体线程栈信息,一定程度影响排查效率。

这里,可以定位到内存申请主要是跟 Hive-parquet-zstd 相关。



Hive-Parquet 分析 -- 问题定位

→ 胡伟华 → 张云帆 在 Parquet 社区找到了一个类似 Case 的 MR — https://github.com/apache/parquet-mr/pull/982,这里改动的点差异如下(第一个图 是 flink 使用的 parquet 版本,第二个图是 parquet 最新的代码版本):

parquet 版本



臧传奇 2023年6月29日

是否这个也暴露出内部 Parquet 版本过低,好多 Bugfix 没有及时 port 过来啊



王蒙 2023年6月29日

@臧传奇 是的,其他的依赖也 会有类似问题,这个还比较难避免

```
Decompled.class file, bytecode version 52.0 (bax 8)

Decompled.class file, bytecode version 52.0 (bax 9)

Decompled.class file, bytecode v
```

这个方法在内存火焰图上也能清楚的看到:

```
libc malloc
com/github/juben/zstd/ZstdInputStream.createDStream
com/github/juben/zstd/ZstdInputStream.cinl>
com/github/juben/zstd/ZstdInputStream.cinl>
org/apache/flink/connectors/hive/shaded/parquet/hadoop/codec/ZstdDecompressorStream.cinl>
org/apache/flink/connectors/hive/shaded/parquet/hadoop/codec/ZstdDecompressorStream.cinl>
org/apache/flink/connectors/hive/shaded/parquet/hadoop/codec/ZstandardCodec.createInputStreamInternal
org/apache/flink/connectors/hive/shaded/parquet/hadoop/codec/ZstandardCodec.createInputStream
org/apache/flink/connectors/hive/shaded/parquet/hadoop/Coder_factory-steapStreamStream
org/apache/flink/connectors/hive/shaded/parquet/hadoop/Coder_factory-steapStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamStreamS
```

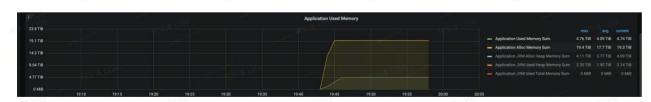
到这里,基本上问题大概率已经明确,<mark>经过线上任务验证后,也确认是这个 parquet bug 导致的线上堆外内存泄露</mark>。

验证效果

修复前,作业内存的使用:



修复后,作业内存的使用:



其他堆外内存工具分析

这里,也介绍一些其他的堆外内存排查工具。

Native Memory Tracking

这个工具可以看到 Java Heap、Class、Thread、Code、GC、Compiler、Internal、Other、Symbol、Native Memory Tracking、Arena Chunk 这几部分的内存使用情况。Native Memory Tracker 这里看到的内存使用与 jeprof 看到的差异比较大,原因是Native Memory Tracker 无法 track JNI 调用的内存信息(这个工具在这个 case 中是无效的)。

内存的使



刘首维 2023年6月29日

赞,预期可以很好地提升我们这 边 Flink Batch 作业的稳定性 这个只能监控 JVM 原生申请的内存大小,如果是通过 JDK 封装的系统 API 申请的内存,是统计不到的,例如 Java JDK 中的 DirectBuffer 以及 MappedByteBuffer 这两个(当然,对于这两个,我们后面也有其他的办法去看到当前使用的大小。当然xigao dog 啥都不会)。以及如果你自己封装 JNI 调用系统调用去申请内存,都是 Native Memory Tracking 无法涵盖的。

--- 见:全网最硬核 JVM 内存详解(上) | HeapDump性能社区

使用命令如下:

- 1 # 通过下面的参数打开
- 2 -XX:NativeMemoryTracking=detail

3

/opt/tiger/jdk/jdk1.8/bin/jcmd 13 VM.native_memory detail >
/opt/tiger/yodel/log/memory-detail.log

Pmap 分析

可以参考 Flink Batch任务使用过多堆外内存分析。

addr2line

使用方式参考 EAndroid Native入门 ,这个工具可以根据 0x00007f69d53189cd 与对应的so包,直接定位到具体的代码行。

- 1 sudo apt-get update
- 2 sudo apt-get install binutils

3

4 addr2line 0x00007fd852b2ab68 -e
 /opt/tiger/yodel/container/tmp/libzstd-jni6415142372855756955.so f -C -s

复盘及 Todo

	40 mil 1359	1359	App. 18 1359	何家施 1359
思考		总结		
Why? 为什么问题?	会发生这个	 Flink hive 依赖包的 bug 	导致;	
Why? 为什么 段没有发现?	测试/灰度阶	特殊场景(hive-zstd rea 触发;	ad)才会触发,并且数据	居量小的时候不会
		• 现在的性能测试流程还不	会对内存的资源使用进	行对比验证 ;
Why? 为什么错?	系统不能容	• 内存泄露的 case,系统原	层没有办法进行自动容错	何常进 1359
Can? 能不能 题?	更早发现问	触发条件比较特殊;一般情况下,加资源可以的问题;	人 cover,也不会意识到这	这个是内存泄露
Can? 解决过 快?	程能不能更	线上可能也有不少类似问上影响没有那么大;这次是在测试环境,大数		
何宗谦上 進 1359	何奈謹 1359	• 堆外分析成本比较高,一		第130 2
		完善测试流程:需要考虑	是在测试流程中引入对资源	源使用的对比;

0x00007fd852b2ab68



臧传奇 2023年6月29日

这个地址用法不准确,因为这是一个动态内存地址;应该根据这个地址,减去 zstd-jni.so 的初始地址,得到偏移地址,addr2line 进而使用偏移地址,获得偏移地址指向的源代码;



王蒙 2023年6月29日

@臧传奇 需要减去7f69d5271000 这个起始地址?



臧传奇 2023年6月29日

@王蒙 对

完善堆外内存排查工具,降低排查成本;



Evan Huang 2024年8月12日 现在有什么工具和文档指示下吗?



王蒙 2024年8月12日

https://flink.bytedance.net/16 45/268150

最新的、高效的使用方式,已经 记录到我们的用户文档里了



王蒙 2024年8月12日

线上镜像默认已经加了 jemalloc 依赖,可以通过动态参 数开启

ToDo

- ✓ Hive Parquet zstd 维外内存问题修复; P0 + 苏德伟 → 张云帆 + □ 2023年7月6日 18:00 ♀
- ☑ 推外内存排查工具完善(覆盖 Streaming + Batch, Godel + Yarn 场景); P1 + □ 王蒙 □ 马春辉 □ 郦泽坤 □ 曹帝胄 □
- ☑ ByteDog 平台能支持 Flink 大数据场景的内存分析(需要跟 sys 同学对齐);
 —— 郦泾坤 —— 臧传奇——

升级parquet版本以修复内存泄漏问题

作业: https://data.bytedance.net/dorado/development/node/110343898? project=cn_6199&version=-1

当前线上版本:

https://cloud.bytedance.net/megatron/jobs/application_1688443034999_2787409/



作业直接Fail,无法运行。

stage版本: 1.0.0.5583

https://cloud.bytedance.net/megatron/jobs/application_1688443034999_2709005/



将parquet-hadoop版本升级至1.10.1-bd1.0.33-zstd-1.4,主要就是加上close,可以看到还是有缓慢内存泄漏。

stage版本: 1.0.0.5585

https://cloud.bytedance.net/megatron/jobs/application_1688443034999_2838124/



几乎和85版本保持一致,可以得知添加close逻辑后修复了一部分问题,但是还是有一些 缓慢泄漏的情况存在。

				可宗谨 1359		
				何宗谨 1359		
				同宗谨 1359		
				向宗道 1359		
				何宗權 1359		
				阿索權 1359		
				同宗道 1359		
				向宗道 1359		
				向宗道 1359		
				阿宗謹 1359		
				可宗谨 1359		
				何宗謹 1359		